

西电官网数据 RAG 智能检索系统项目启动与规划

1. 团队组建与角色分配

1.1 项目目标

本项目拟建设一个面向西安电子科技大学学生的官网数据 RAG 智能检索系统。系统采集学校公开官网页面，清洗并构建本地知识库，支持学生用自然语言查询学校政策、推免/保研、生活安排、竞赛通知、教务信息、学工通知等内容，并返回带官方来源引用的答案。

首版系统以“可运行、可演示、来源可信、拒绝无依据回答”为核心目标，避免模型编造未被官方资料支持的内容。

1.2 团队角色

陈天路：网站全栈开发

杨昊炜 王思帆：进行网站测试 配置 API

纪依程 温阳：知识库获取 文档编写

1.3 协作机制

- 任务管理工具：Plane。
- 代码管理：Git，本地开发后统一合并到主分支。

2. 产品 Backlog（Plane）

2.1 Plane 项目配置建议

项目名称：XDU_RAG

workflow状态：

状态	含义
Backlog	已记录但暂未进入迭代
Todo	本迭代计划完成
In Progress	正在开发或整理
In Review	已完成，等待评审/测试
Done	已验收完成

模块标签：

- 需求分析
- 数据采集
- 知识库

- RAG 问答
- 后端 API
- 前端界面
- 测试
- UML 建模
- 文档

最终项目完成后，在 plane 上有接入外部 Embeddedding API 未完成外，其余计划均已经完成。

X

Xdu_Rag

Search

Get Started

?

AI assistant

Projects

New work item

Home

Drafts

Your work

Stickies

Workspace

Projects

More

Projects

Xdu_Rag

Overview

Work items

Cycles

Modules

Views

Pages

Try

Connect to GitHub

Connect to Slack

Try Plane AI

Business trial ends in 13d

Xdu_Rag

Work items

24

24 Work items

Week

Month

Quarter

Today

Display

Analytics

Add work item

Work items	Duration	Apr - Jun 2026			
		Apr	May	Jun	Jul
XDURA-8 建立项目 Backlog 与 workflow	2 days	建			
XDURA-9 编写目标用户与需求说明	2 days	编			
XDURA-10 绘制 UML 用例图	2 days	绘			
XDURA-11 配置官网白名单数据源	4 days	配			
XDURA-12 实现网页抓取与原文保存	6 days	实..			
XDURA-13 实现 HTML 正文抽取与文档生成	6 days	实..			
XDURA-14 支持本地 HTML 原文导入	6 days	支..			
XDURA-15 实现文本切片与索引构建	5 days	实			
XDURA-16 实现本地向量检索	5 days	实			
XDURA-17 支持分类过滤检索	5 days		支		
XDURA-18 实现 RAG 问答与拒答机制	8 days		实..		
XDURA-19 接入 DeepSeek Chat	1 day		接		
XDURA-20 接入 Qwen Embedding	1 day		接		
XDURA-21 支持 Chroma 向量库	4 days		支		
XDURA-22 实现健康检查接口	8 days		实..		

+ New work item

Plane AI (GPT-5.4)

Suggestions

Create a Page in the Wiki with work logs for each member in the last month

Create a Sticky with details of all Urgent workitems across this workspace

Xdu_Rag

How can I help you today?

+ Build

Plane AI can make mistakes, please double-check responses.

图 1plane 初始




图 2plane 项目完成

2.2 Epic 与用户故事

Epic 1: 需求分析与项目建模

Plane Issue	类型	描述	验收标准
明确目标用户与使用场景	Story	梳理学生查询政策、保研、生活、竞赛、教务、学工信息的典型场景	文档中包含目标用户、核心痛点、主要使用场景
编写功能性与非功能性需求	Story	明确系统必须支持的功能和质量要求	形成需求列表，覆盖采集、检索、问答、引用、拒答、前端展示
绘制 UML 用例图	Task	使用 UML 工具绘制学生、系统管理员与系统的交互	用例图包含问答查询、分类筛选、更新知识库、查看引用等用例

Plane Issue	类型	描述	验收标准
绘制 UML 类图/组件图	Task	展示核心模块关系，如爬虫、切片、向量存储、问答服务、API	图中体现主要类/组件及依赖关系

Epic 2: 官网数据采集与清洗

Plane Issue	类型	描述	验收标准
维护官网数据源白名单	Story	配置西电主站、综合信息网、信息公开网、教务处、研究生院、学生工作部等官方网站	config/sources.json 中包含允许域名、种子 URL 和默认分类
实现网页抓取与失败记录	Story	按白名单抓取公开页面，并记录无法访问页面	可执行 <code>xidian-rag crawl --max-pages 120</code> ，失败项写入日志
保存原始 HTML 快照	Task	保存抓取到的原始页面，便于复现和离线导入	原文写入 <code>data/knowledge_base/pages/</code>
实现 HTML 正文抽取	Story	从网页中抽取标题、正文、发布时间、链接等信息	生成结构化 <code>data/documents.jsonl</code> ，短文本和重复文本会被过滤
支持手动导入 HTML 原文	Story	允许把网页原文放入目录后离线生成文档	<code>xidian-rag ingest-pages</code> 能从本地 HTML 生成文档

Epic 3: 知识库构建与检索

Plane Issue	类型	描述	验收标准
实现文本切片	Story	将长文档切分为适合检索的文本块	生成 <code>data/chunks.jsonl</code> ，短文本保留，长文本合理切分
实现本地哈希向量检索	Story	无 API Key 时仍可进行基础向量检索	默认 <code>VECTOR_STORE=local</code> 时可构建索引并搜索
接入 Qwen Embedding	Story	配置 API Key 后使用外部 Qwen embedding 模型提升效果	<code>USE_API_EMBEDDINGS=true</code> 时可调用配置的 embedding 接口
支持 Chroma 向量库	Story	提供持久化向量数据库作为可选存储	安装可选依赖并设置 <code>VECTOR_STORE=chroma</code> 后可构建和查询
支持分类过滤检索	Story	问答时可按政策、保研、生活、竞赛、教务、学工过滤	查询接口支持 <code>category</code> 参数，前端可选择分类

Epic 4: RAG 问答服务

Plane Issue	类型	描述	验收标准
实现基于检索结果的问答	Story	根据命中的官方资料生成回答	命中资料时返回答案、引用、来源、相似度
实现无依据拒答机制	Story	检索不到可靠资料时不编造答案	空知识库或低分命中时返回“未找到依据”
接入 DeepSeek Chat	Story	配置 API 后由模型基于上下文生成更自然回答	<code>USE_API_CHAT=true</code> 且配置 API Key 时可生成答案
实现抽取式兜底回答	Story	未配置模型或模型调用失败时仍可演示	系统能返回片段式答案并提示以原文为最终依据
引用来源去重与摘要展示	Task	避免重复引用，展示标题、链接、来源站点、发布时间和片段	返回结构化 <code>citations</code> ，前端可展示

Epic 5: 后端 API 与前端界面

Plane Issue	类型	描述	验收标准
实现健康检查接口	Task	提供服务运行状态检查	<code>GET /health</code> 返回 <code>status=ok</code>
实现数据源接口	Task	返回允许域名、种子站点、分类信息	<code>GET /sources</code> 返回配置数据
实现统计接口	Task	返回知识库切片数量和分类分布	<code>GET /stats</code> 可查看索引状态
实现问答接口	Story	提供自然语言问答 API	<code>POST /ask</code> 支持 <code>question</code> 、 <code>category</code> 、 <code>top_k</code>
实现 Streamlit 问答前端	Story	提供学生可直接使用的问答页面	页面支持输入问题、选择分类、展示答案和引用
增加前端错误提示	Task	当后端未启动、知识库为空或 API 异常时给出清晰提示	用户能理解失败原因和下一步操作

Epic 6: 测试、验收与提交文档

Plane Issue	类型	描述	验收标准
编写核心单元测试	Story	覆盖分类、切片、原文保存、导入、空库拒答、检索命中	python -m unittest 通过
设计系统测试用例	Task	覆盖正常问答、分类筛选、空库拒答、API 失败兜底等	形成测试用例表
准备演示数据和演示问题	Task	选择若干官网页面并准备典型问题	演示时可稳定展示查询结果和引用
整理项目 Word 文档	Story	汇总项目规划、需求、UML、技术方案、测试、截图	文档结构完整，内容与系统一致

3. 技术方案

3.1 实现语言与框架

层次	技术选型	选择理由
主要语言	Python 3.10+	适合爬虫、文本处理、RAG 原型和 Web API 开发
后端 API	FastAPI + Uvicorn	接口开发简洁，自动支持请求校验，便于演示和扩展
前端界面	Streamlit	快速构建可交互问答界面，适合课程项目展示
网页抓取	requests + BeautifulSoup4	依赖轻量，适合抓取公开静态网页和解析 HTML
向量检索	本地 JSON 向量索引 / Chroma 可选	默认不依赖外部服务；后续可切换到持久化向量数据库
大模型接口	DeepSeek API 可选	支持接入 DeepSeek 或兼容服务；无 Key 时仍可用抽取式回答
测试框架	unittest	Python 标准库内置，环境要求低

3.2 存储方式

数据	存储位置	说明
数据源配置	config/sources.json	保存允许域名、种子 URL、分类关键词
原始网页快照	data/knowledge_base/pages/	保存抓取到的 HTML 原文，便于复现和离线导入
结构化文档	data/documents.jsonl	保存标题、正文、来源、分类、发布时间等
文本切片	data/chunks.jsonl	保存适合向量检索的 chunk
本地向量索引	data/index/	默认向量存储，无需额外服务
Chroma 向量库	data/chroma/	可选持久化向量数据库
抓取失败日志	data/crawl_failures.jsonl	记录访问失败原因，便于排查

3.3 体系结构

系统采用分层架构，分为数据采集层、知识处理层、检索问答层、接口层和展示层。

3.4 核心模块说明

模块	文件/目录	职责
----	-------	----

模块	文件/目录	职责
数据源配置	config/sources.json	管理官网白名单、种子站点和分类关键词
爬虫模块	src/xidian_rag/crawler.py	抓取网页、解析 HTML、保存原始快照、生成文档
分类模块	src/xidian_rag/categorizer.py	根据关键词判断政策、保研、生活、竞赛等分类
切片模块	src/xidian_rag/chunking.py	将文档正文拆分为检索片段
Embedding 模块	src/xidian_rag/embeddings.py	支持本地哈希向量和 API embedding
向量存储	src/xidian_rag/vector_store.py	支持本地索引和 Chroma 检索
RAG 服务	src/xidian_rag/rag.py	检索、置信度判断、引用生成、拒答和回答生成
API 服务	src/xidian_rag/api.py	对外提供健康检查、数据源、统计和问答接口
前端页面	app/streamlit_app.py	提供学生问答入口和结果展示
命令行入口	src/xidian_rag/cli.py	支持 crawl、ingest-pages、index、ask 等命令

3.5 关键设计原则

- 可信来源：只采集学校公开、官方、可访问页面，不绕过登录、VPN 或权限限制。
- 有据可查：答案必须带引用，引用中包含标题、URL、来源站点、分类、发布时间和片段。
- 缺证拒答：当知识库为空或相似度不足时，系统明确说明未找到官方依据。
- 可离线演示：无 API Key 时仍可使用本地哈希向量和抽取式回答完成流程演示。
- 可扩展：后续可扩展更多官网来源、增量更新、权限管理、历史问答记录和更强的向量数据库。

4. 迭代计划

迭代	目标	主要任务	交付物
迭代 0：项目启动与需求建模	完成项目方向、角色分工、需求范围和 UML 初稿	分配角色；建立 Plane 项目；梳理用户故事；绘制用例图；确认官网数据源范围	项目启动文档、Plane Backlog、用例图
迭代 1：数据采集与知识库 MVP	打通从官网页面到本地知识库的流程	配置白名单；实现抓取；保存 HTML；抽取正文；生成 documents.jsonl；实现文本切片	可运行的 crawl、ingest-pages、index 命令
迭代 2：检索问答与接口服务	打通学生提问到答案与引用返回的流程	实现本地向量检索；实现分类过滤；实现拒答；完成 /ask、/sources、/stats、/health 接口	可通过 API 完成问答查询
迭代 3：前端演示、测试与文档提交	完成可演示系统和课程提交材料	实现 Streamlit 页面；准备演示数据；编写测试；补充 UML 类图/组件图；整理 Word 并导出 PDF	前端演示、测试报告、最终 PDF